Proyecto de Analítica de Clientes

Integrantes: Verónica Cereceda
Diego Torres
Cristian Urcullu
Docente: Jazna Meza
Asignatura: Programación para la Ciencia de Datos
Sección: 001D
Fecha entrega: 08-04-2026

Índice

Resumen ejecutivo..... **2**
Análisis exploratorio inicial..... **3**
Metodología de transformación.....**4**
Limpieza de Datos.....4
Resultados y validación..... **9**

Resumen ejecutivo

El proyecto tiene como objetivo analizar un conjunto de datos de clientes de una empresa de servicios digitales por suscripción, con el fin de comprender su comportamiento e identificar variables y patrones que influyen en la cancelación del servicio. Para ello, se desarrolló un flujo completo utilizando Python, Pandas y NumPy, que incluye análisis exploratorio, limpieza de datos y transformación de variables.

Entre los principales hallazgos, se identificaron patrones relevantes en variables numéricas y categóricas, presencia de *outliers* y datos inconsistentes, los cuales fueron tratados mediante técnicas como eliminación de duplicados, manejo de valores nulos y la aplicación de Winsorización. Esto permitió obtener un dataset consistente, sin valores nulos ni duplicados, con variables estabilizadas y completamente preparado para análisis predictivo.

Análisis exploratorio inicial

Se realizó una inspección profunda del dataset para comprender la estructura y calidad de la información antes de cualquier intervención técnica.

El conjunto de datos procesado agrupa información demográfica, económica y de comportamiento de los clientes de servicios digitales. Se identificó una estructura mixta compuesta por:

- Variables Categóricas: Permiten segmentar a los usuarios según atributos cualitativos.
- Variables Numéricas: Proporcionan métricas cuantitativas sobre el consumo y la facturación, fundamentales para identificar patrones de abandono.

Se detectó la presencia de valores nulos y registros duplicados, además de una alta dispersión en variables financieras, lo que confirmó la necesidad de un flujo de limpieza robusto.

Para entender la distribución y detectar anomalías, se calcularon medidas estadísticas clave utilizando las librerías Pandas y NumPy:

Se utilizaron métricas como la media y la mediana para identificar el comportamiento típico de los clientes dentro del servicio de suscripción. La comparación entre ambas medidas permitió determinar la presencia de sesgos en los datos, lo cual es indicativo de distribuciones no simétricas que podrían afectar la interpretación de variables clave como la facturación mensual o la antigüedad.

El cálculo de la desviación estándar, junto con los valores mínimos y máximos, proporcionó una visión clara sobre la variabilidad de la información. Estas métricas revelaron una alta dispersión en variables financieras, confirmando la existencia de valores atípicos. La identificación de estos puntos es crucial, ya que su permanencia sin un tratamiento adecuado podría distorsionar significativamente los modelos predictivos.

Se utilizaron dos tipos de gráficos para caracterizar visualmente el dataset los cuales son:

- Histogramas: Implementados para analizar la frecuencia y forma de las distribuciones numéricas.
- Boxplots: Herramienta principal para la detección visual de *outliers* y la validación de la dispersión identificada estadísticamente.

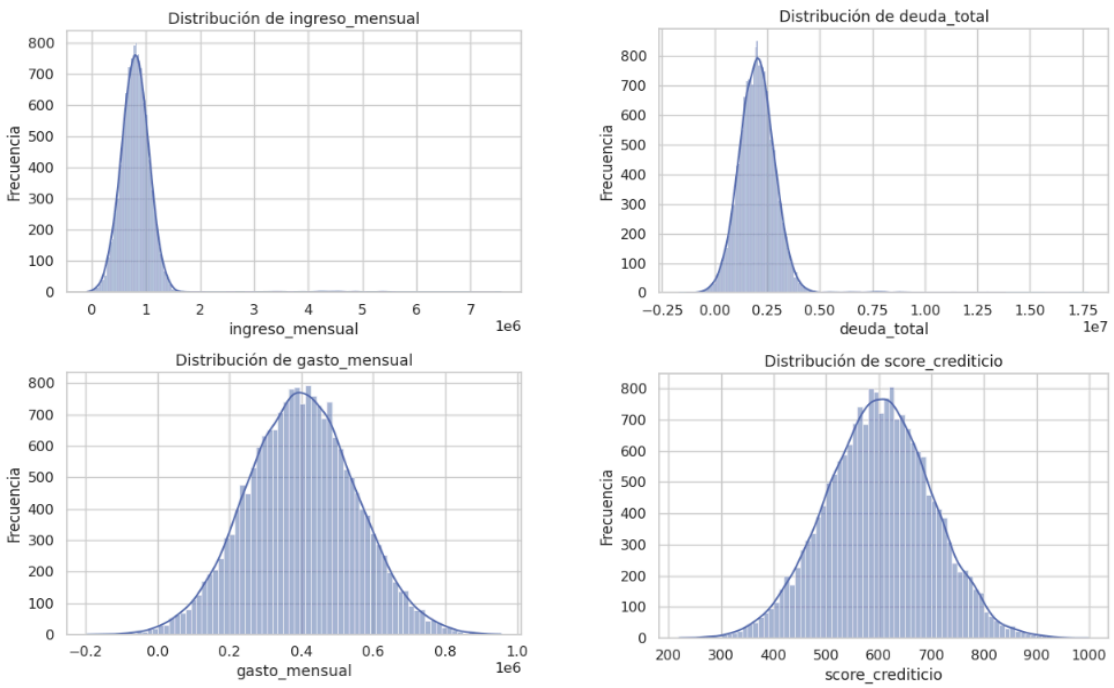
Distribución de ingreso_mensual
Frecuencia
ingreso_mensual
1e6
Distribución de deuda_total
Frecuencia
deuda_total
1e7
Distribución de gasto_mensual
Frecuencia
gasto_mensual
1e6
Distribución de score_crediticio
Frecuencia
score_crediticio

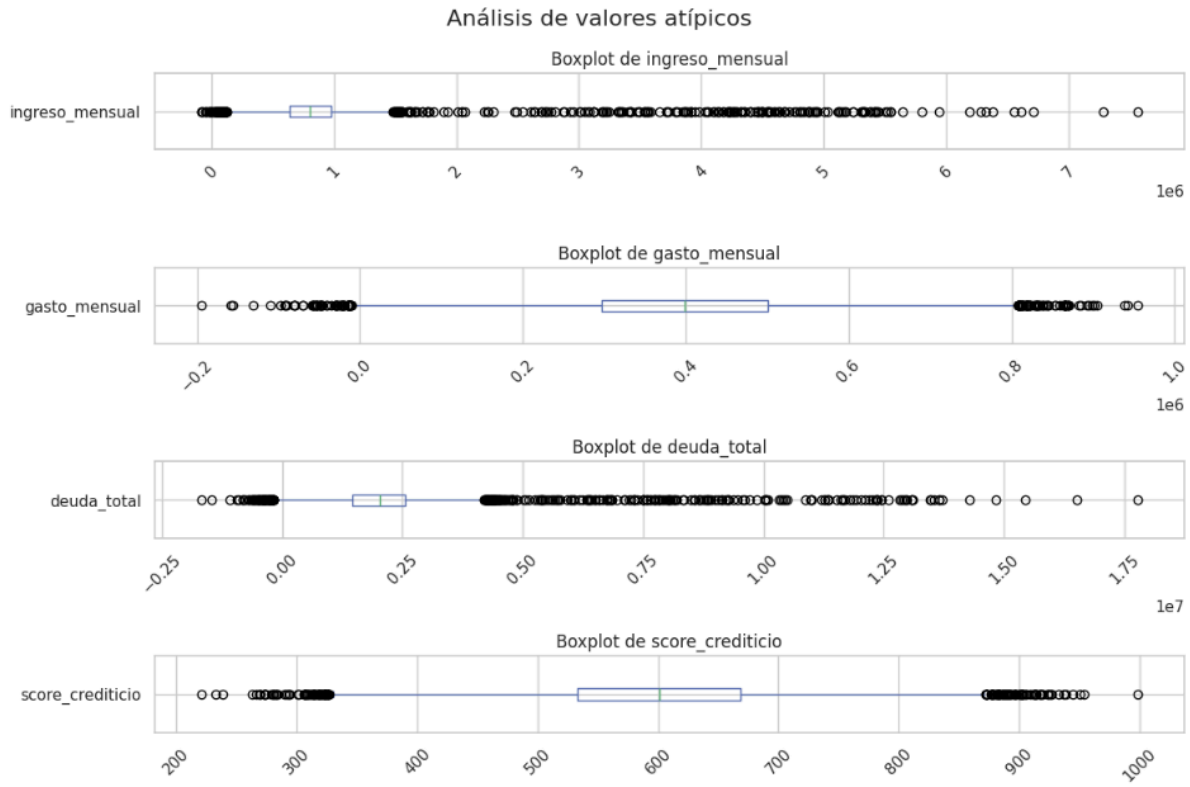
Análisis de valores atípicos
Boxplot de ingreso_mensual
ingreso_mensual
1e6
Boxplot de gasto_mensual
gasto_mensual
1e6
Boxplot de deuda_total
deuda_total
1e7
Boxplot de score_crediticio
score_crediticio

Metodología de transformación

En esta etapa, el proyecto se enfocó en convertir los datos crudos en información de alta calidad. Para lograrlo, se diseñó un flujo de trabajo organizado que asegura que cada variable reciba el tratamiento adecuado según su naturaleza.

Limpieza de Datos

La limpieza se ejecutó bajo criterios de estabilidad estadística y preservación de información, utilizando las librerías Pandas y NumPy para asegurar precisión en cada operación.
Eliminación de duplicados: Se identificaron y se eliminaron registros idénticos para evitar que el análisis estadístico se vea afectado por datos repetidos. Esto garantiza que cada fila represente a un cliente único y que los cálculos de percentiles sean exactos.

Inconsistencias: Se detectó que columnas críticas como ingreso_mensual, gasto_mensual y deuda_total contenían valores negativos, lo cual es un error lógico en datos financieros. El proyecto decidió transformar estos valores negativos en NaN para tratarlos posteriormente mediante imputación, evitando así que datos erróneos ensucien el promedio.

Tratamiento de Outliers: Para manejar los valores extremos,se utilizó un Winsorizer,donde se aplicaron límites de 5% y 95%. Esto significa que los valores extremadamente altos o bajos se ajustan a estos límites en lugar de ser eliminados.

Esta técnica asegura la integridad del conjunto de datos al conservar la totalidad de los registros originales, evitando la pérdida de información que ocurriría al eliminar filas. Esto permite que el dataset sea estadísticamente más estable y que los patrones identificados en el análisis sean precisos y no se vean alterados por anomalías.

Separación y Organización de Variables: El proyecto dividió el conjunto de datos para aplicar soluciones específicas a cada grupo:

- **Variables Numéricas con Outliers:** ingreso_mensual, gasto_mensual, deuda_total y score_crediticio. Recibieron un tratamiento doble imputación y winsorización.
- **Variables Numéricas Estándar:** Aquellas sin valores atípicos detectados en el análisis inicial.
- **Variables Categóricas:** Atributos cualitativos que definen el perfil del usuario.

Flujos de Procesamiento: Para automatizar la limpieza y evitar errores manuales, se utilizaron Pipelines:

- **Imputación Numérica:** Para las variables numéricas, se utilizó la mediana como estrategia de relleno.Se eligió esta medida por ser más robusta que el promedio, ya que no se deja afectar por los valores extremos, manteniendo la distribución original de los datos.
- **Imputación Categórica:** En el caso de los datos cualitativos, se utilizó la moda.Esto permite completar los registros vacíos con la categoría más lógica y común dentro del comportamiento de los clientes.

Integración Final del Dataset: El paso final consistió en unir todos los subconjuntos ya procesados. Esta integración consolida un dataset final totalmente depurado, validado y con sus variables escaladas

Transformación

Una vez completada la etapa de limpieza de datos, se procedió a la transformación del dataset con el objetivo de adaptarlo a los requerimientos de los modelos de machine learning. En esta fase, el foco no estuvo únicamente en convertir las variables a formato numérico, sino también en mejorar su representatividad y coherencia con el fenómeno de estudio.

El proceso de transformación se diseñó a partir de los hallazgos obtenidos en el análisis exploratorio, permitiendo aplicar decisiones informadas sobre qué variables mantener, modificar o eliminar.

Selección y depuración de variables

Como primer paso, se evaluó la utilidad analítica de cada variable presente en el dataset limpio. En base a este análisis, se eliminaron aquellas que no aportaban valor predictivo o que podían introducir ruido en el modelo:

- **id_cliente**: corresponde a un identificador único sin capacidad predictiva.
- **codigo_postal**: presenta alta cardinalidad, lo que dificulta su generalización y aumenta la complejidad del modelo.
- **fecha_registro**: fue reemplazada por variables derivadas más interpretables.
- **hora_registro** y **dia_semana_registro**: fueron transformadas a variables cíclicas.
- **mes**: eliminado tras su transformación a representación seno/coseno.

Esta etapa permitió simplificar el dataset, reduciendo redundancias y mejorando su eficiencia.

Ingeniería de características

En esta fase se incorporaron nuevas variables y transformaciones con el objetivo de enriquecer la información disponible.

Transformación temporal:

A partir de la variable fecha_registro, se extrajo la variable anio, permitiendo capturar tendencias en el tiempo. Las variables temporales restantes fueron tratadas de forma más avanzada mediante transformación cíclica.

Variables cíclicas:

Se identificó que ciertas variables no debían representarse linealmente, ya que su naturaleza es periódica. Por ello, se aplicaron funciones seno y coseno sobre:

- hora de registro
- mes
- día de la semana

Esto permite representar correctamente la cercanía entre valores extremos del ciclo (por ejemplo, entre las 23:00 y las 00:00 horas).

Variables derivadas con sentido de negocio:

Se incorporaron variables adicionales que representan relaciones financieras relevantes:

- ratio_deuda_ingreso
- ratio_gasto_ingreso

Estas variables permiten modelar de forma más directa la presión financiera del cliente, lo cual es especialmente relevante para el análisis del abandono.

Aplicación de técnicas de transformación

Se aplicaron distintas técnicas de transformación según el tipo de variable:

Escalamiento de variables numéricas:

Se utilizó StandardScaler, que estandariza las variables a una distribución con media 0 y desviación estándar 1. Esto evita que variables con mayor magnitud dominen el aprendizaje del modelo.

Codificación de variables categóricas:

Se aplicó OneHotEncoder, generando variables binarias para cada categoría. Esto permite representar información cualitativa sin introducir relaciones artificiales de orden.

Variables binarias:

La variable tiene_tarjeta_credito se mantuvo sin transformación, ya que su formato binario es directamente interpretable.

Variables cíclicas:

Las variables transformadas mediante seno y coseno se incorporaron sin escalamiento adicional, sus valores ya quedaron entre -1 y 1, así que se incorporan directamente manteniendo su estructura periódica.

Esta clasificación permitió definir el tratamiento específico para cada grupo.

Integración mediante pipeline

Para garantizar consistencia y reproducibilidad, se utilizó un ColumnTransformer, el cual permitió aplicar todas las transformaciones de manera estructurada dentro de un mismo flujo.

Este pipeline integra:

- escalamiento de variables numéricas
- codificación de variables categóricas
- incorporación directa de variables binarias
- inclusión de variables cíclicas

El uso de este enfoque evita errores manuales y asegura que el mismo proceso pueda replicarse en nuevos datos.

Resultado de la transformación

El resultado final corresponde a un dataset completamente transformado, compuesto por:

- 20000 registros
- 37 variables explicativas transformadas
- 1 variable objetivo (abandono)

Todas las variables se encuentran en formato numérico, sin valores faltantes y con una estructura adecuada para el entrenamiento de modelos de machine learning.

Resultados y validación

Una vez concluida la limpieza y la transformación, se validó la calidad del dataset resultante para verificar que el flujo aplicado efectivamente mejorará su consistencia y lo dejará listo para etapas de modelado.

Validación post-limpieza
En esta etapa se confirmó que:

- los registros duplicados fueron eliminados
- las inconsistencias financieras fueron corregidas mediante conversión a valores faltantes e imputación
- los valores faltantes fueron resueltos completamente
- el efecto de los outliers fue moderado mediante winsorización, reduciendo la influencia de valores extremos sin perder observaciones

Esto permitió obtener un dataset limpio y estructuralmente estable, manteniendo la mayor parte de la información original.

Validación post-transformación
Luego de aplicar el pipeline, se verificó que:

- el dataset final quedó completamente en formato numérico
- no quedaron columnas de tipo `object`
- las variables categóricas se expandieron correctamente mediante `OneHotEncoder`
- las variables numéricas fueron escaladas
- las variables cíclicas conservaron su representación periódica adecuada
- la variable objetivo `abandono` fue reincorporada al dataset transformado como columna final, manteniendo separado el proceso de transformación de las features respecto del target

La inspección del dataframe transformado mostró una estructura consistente de 38 columnas, de las cuales 37 corresponden a variables explicativas y 1 a la variable objetivo.

Impacto de la transformación
Las transformaciones aplicadas mejoran tanto la calidad técnica como el valor analítico del dataset:

- la estandarización redujo el sesgo por diferencias de escala entre variables numéricas
- la codificación categórica permitió integrar atributos cualitativos sin introducir órdenes artificiales
- la transformación cíclica corrigió representaciones lineales inadecuadas de variables temporales
- la eliminación de variables irrelevantes redujo ruido y complejidad innecesaria
- la creación de ratios financieros agregó señales con sentido de negocio que no estaban explícitamente presentes en el dataset original

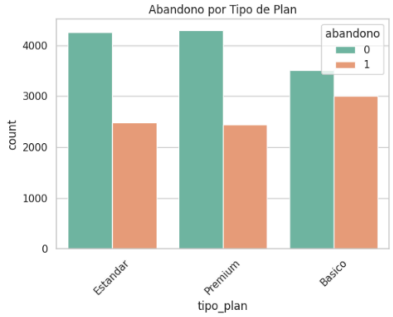

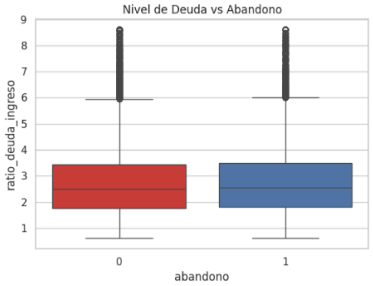

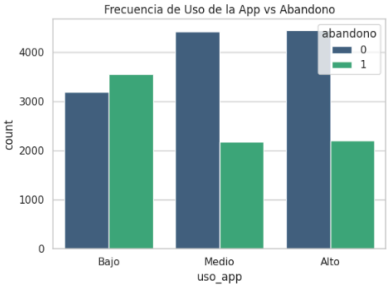

En conjunto, el resultado no fue solo un dataset “limpio”, sino una representación más informativa y más útil para detectar patrones asociados al abandono del cliente.

Conclusiones y recomendaciones

El desarrollo de este proyecto permitió transformar un conjunto de datos brutos en un dataset de alta calidad. A través de la eliminación de duplicados y la corrección de inconsistencias lógicas, se aseguró la unicidad de los registros, mientras que la técnica de Winsorización mitigó el impacto de los valores atípicos identificados en el análisis exploratorio inicial sin reducir el volumen de los datos originales. La implementación de procesos de imputación por mediana y moda permitió completar las variables de manera lógica, eliminando sesgos y fortaleciendo la robustez del procesamiento. Finalmente, la etapa de transformación mediante la codificación de variables categóricas y la estandarización de escalas permitió que los datos alcanzaran el formato técnico necesario para ser procesados por modelos de aprendizaje automático. Este resultado final cumple con los estándares de calidad y validación exigidos, recomendándole la automatización de este flujo mediante scripts modulares para asegurar la reproducibilidad del entorno en proyectos de similares característica